Experimentación y resultados

Algoritmo propuesto de la etapa 1

Vanessa Alejandra Mecott Maldonado | Equipo 5

Sección individual para integrar al reporte del equipo.

1 Experimentación del algoritmo propuesto: genético con Split

1.1 Alcance y continuidad con las etapas anteriores

Se tomó como algoritmo propuesto el genético con decodificación Split incluido en el Anexo 3 del Entregable 1 del Equipo 5 [3]. Esta identificación es un supuesto de trabajo adoptado para avanzar con la experimentación: no representa un cuarto método independiente del algoritmo genético. La comparación de cuatro métodos debe aclarar esta coincidencia al integrar el reporte del equipo.

El cromosoma es una permutación de todos los clientes, llamada tour gigante. Split encuentra la partición de menor distancia de ese orden en rutas factibles, siguiendo la idea de decodificación por programación dinámica de Prins [4]. La optimalidad del Split se limita a los cortes de una permutación dada; no implica optimalidad global del CVRP. Los genéticos se han estudiado para este problema [1], pero esta implementación académica no reproduce íntegramente esos algoritmos publicados.

1.2 Configuración y protocolo experimental

Elemento	Configuración fija de la etapa 1
Población y generaciones	60 individuos; 150 generaciones
Selección	Torneo de tamaño 3
Cruce	Segmento de dos cortes, llenado lineal por orden
Probabilidad de cruce	0.90 por hijo
Probabilidad de mutación	0.25 por hijo
Mutación	Intercambio o inversión, 50% cada una
Elitismo	2 mejores individuos
Inicialización	Permutaciones completamente aleatorias
Paro	150 generaciones, sin paro por estancamiento
Corridas	3 por instancia; semillas 0, 1 y 2

Se evaluaron 24 instancias (14 CMT y 10 X), para un total de 72 corridas. Cada corrida realizó $60(150+1) = 9060$ evaluaciones de individuos, incluyendo la población inicial y la reevaluación de los élites. La reconstrucción final se contabilizó por separado. Una generación evalúa 60 individuos; no equivale a una iteración de ACO con 8 hormigas. No se añadió búsqueda local ni inicialización heurística. El cruce conserva la variante de los anexos anteriores: copia un segmento inclusivo y llena huecos de izquierda a derecha con el orden del segundo padre; no se intercambió por otra variante circular de OX.

Las distancias se calcularon como euclidianas reales en CMT y como $\lfloor d_{ij} + 0.5 \rfloor$ por arco en X. Se respetaron capacidad y cobertura exacta. Para las instancias con duración máxima se verificó $D_r + s|r| \leq L$, suponiendo velocidad unitaria y servicio únicamente en clientes. El objetivo suma solo distancia, sin sumar servicio. No se impuso un límite adicional de vehículos: los archivos no lo declaran y el algoritmo original tampoco lo imponía. El sufijo k de X se conservó como referencia del nombre. **Si el equipo fija una flota máxima o exacta, estas corridas deben repetirse bajo esa regla antes de compararlas.**

1.3 Resultados en las 24 instancias

Se obtuvieron soluciones factibles en las 72 corridas. La validación volvió a calcular distancia, carga, duración y cobertura a partir de las rutas guardadas. La tabla presenta la media, desviación estándar muestral, mejor distancia, tiempo medio, vehículos medios y generación media de obtención del mejor valor.

Instancia	n	$\bar{Z}$	s_Z	$Z_{\min}$	$\bar{t}$ (s)	$\bar{k}$	$\bar{g}^*$
CMT1	50	651.33	25.67	630.61	0.805	6.33	145.3
CMT2	75	1167.47	12.41	1154.31	1.103	11.33	144.3
CMT3	100	1495.49	88.68	1438.59	2.651	9.00	149.3
CMT4	150	2427.68	56.71	2376.62	3.204	14.33	148.7
CMT5	199	3444.23	112.57	3316.51	6.722	21.33	149.7
CMT6	50	709.33	20.67	687.72	1.335	7.00	148.7
CMT7	75	1330.65	46.59	1302.34	1.248	15.67	148.3
CMT8	100	1612.29	110.01	1494.19	2.459	14.67	148.7
CMT9	150	2782.51	16.69	2763.54	4.202	25.33	147.0
CMT10	199	3734.40	125.67	3597.15	6.446	34.00	149.7
CMT11	120	2544.09	73.34	2470.53	4.052	9.00	149.0
CMT12	100	1636.03	77.52	1552.70	2.025	11.00	149.3
CMT13	120	2823.62	32.62	2786.15	4.466	15.67	148.3
CMT14	100	1541.51	67.71	1463.44	2.252	13.33	149.3
X-n280-k17	279	94190.67	2611.60	91280.00	11.852	20.00	148.7
X-n303-k21	302	70054.67	1839.68	68858.00	10.416	26.67	149.7
X-n308-k13	307	91959.00	1332.85	90467.00	16.301	16.00	149.0
X-n327-k20	326	92945.67	583.11	92397.00	12.152	26.33	148.7
X-n336-k84	335	207330.67	723.45	206509.00	3.987	98.33	149.0
X-n401-k29	400	145088.00	4345.30	140354.00	13.777	31.67	149.7
X-n411-k19	410	92743.00	1817.90	90649.00	23.037	24.33	149.0
X-n429-k61	428	157489.67	2560.32	155479.00	9.366	76.67	150.0
X-n449-k29	448	167432.00	1883.63	166219.00	16.620	34.00	149.7
X-n459-k26	458	93074.00	606.97	92627.00	20.586	35.00	148.3

n: clientes, sin depósito; $\bar{g}^*$: generación del último descenso estricto mayor que 10^{-8} en el mejor valor. Todas las corridas terminaron en la generación 150. $\bar{g}^*$ no es el número total de generaciones ejecutadas.

El tiempo se midió con `perf_counter`, en un proceso secuencial, incluyendo inicialización de población, evolución y reconstrucción final. Se excluyeron lectura, preparación de matriz, validación, escritura de archivos y figuras. El total observado de tiempo de algoritmo fue 543.20 s; las corridas oscilaron entre 0.780 y 23.392 s. Estos tiempos corresponden al entorno de ejecución descrito en `metadatos.json`; una comparación de velocidad con otros métodos requiere ejecutarlos en la misma máquina y con igual alcance del cronómetro.

La reducción media frente al mejor individuo inicial fue de 43.77%, calculada sobre las 72 corridas. El coeficiente de variación por instancia osciló entre 0.35% y 6.82%. Con solo tres repeticiones, estas medidas son descriptivas y no demuestran superioridad estadística.

1.4 Comparación con referencias de la literatura

Se consultó la tabla de CVRPLIB [2], que reúne casos clásicos CMT y la familia X de Uchoa y colaboradores [5]. Los valores se guardaron con fuente y fecha de consulta. La diferencia relativa se calculó como:

$$\Delta_{\text{ref}}(\%) = 100\frac{Z - Z_{\text{ref}}}{Z_{\text{ref}}}.$$

Se reporta como *diferencia con referencia publicada*; no sustituye el GAP respecto al modelo matemático del equipo. La columna "Ópt. pub." reproduce la clasificación de la fuente y no certifica optimalidad de nuestras corridas. La comparación debe conservar convenciones equivalentes de distancia y flota.

Instancia	Z_{ref}	Ópt. pub.	Δ_{media} (%)	Δ_{mejor} (%)
CMT1	524.61	Sí	24.15	20.20
CMT2	835.26	Sí	39.77	38.20
CMT3	826.14	Sí	81.02	74.13
CMT4	1028.42	Sí	136.06	131.09
CMT5	1291.29	Sí	166.73	156.84
CMT6	555.43	Sí	27.71	23.82
CMT7	909.68	Sí	46.28	43.16
CMT8	865.94	Sí	86.19	72.55
CMT9	1162.55	Sí	139.35	137.71
CMT10	1395.85	Sí	167.54	157.70
CMT11	1042.12	Sí	144.13	137.07
CMT12	819.56	Sí	99.62	89.46
CMT13	1541.14	Sí	83.22	80.78
CMT14	866.37	Sí	77.93	68.92
X-n280-k17	33503.00	No	181.14	172.45
X-n303-k21	21736.00	No	222.30	216.79
X-n308-k13	25859.00	No	255.62	249.85
X-n327-k20	27532.00	No	237.59	235.60
X-n336-k84	139111.00	No	49.04	48.45
X-n401-k29	66154.00	No	119.32	112.16
X-n411-k19	19712.00	No	370.49	359.87
X-n429-k61	65449.00	No	140.63	137.56
X-n449-k29	55233.00	No	203.14	200.94
X-n459-k26	24139.00	No	285.58	283.72

La diferencia media no ponderada entre instancias fue de 94.26% en CMT y 206.48% en X. La menor diferencia media se observó en CMT1 (24.15%) y la mayor en X-n411-k19 (370.49%). Los resultados muestran que la configuración original produce soluciones factibles, pero su calidad queda lejos de las referencias en buena parte de estas instancias. Se debe reportar esta limitación, sin atribuirle al algoritmo un desempeño que no obtuvo. Como detalle de trazabilidad, el archivo suministrado CMT11 tiene comentario 1042.11; para esta tabla se usó 1042.12, valor consultado en CVRPLIB.

1.5 Convergencia y tiempo de cómputo

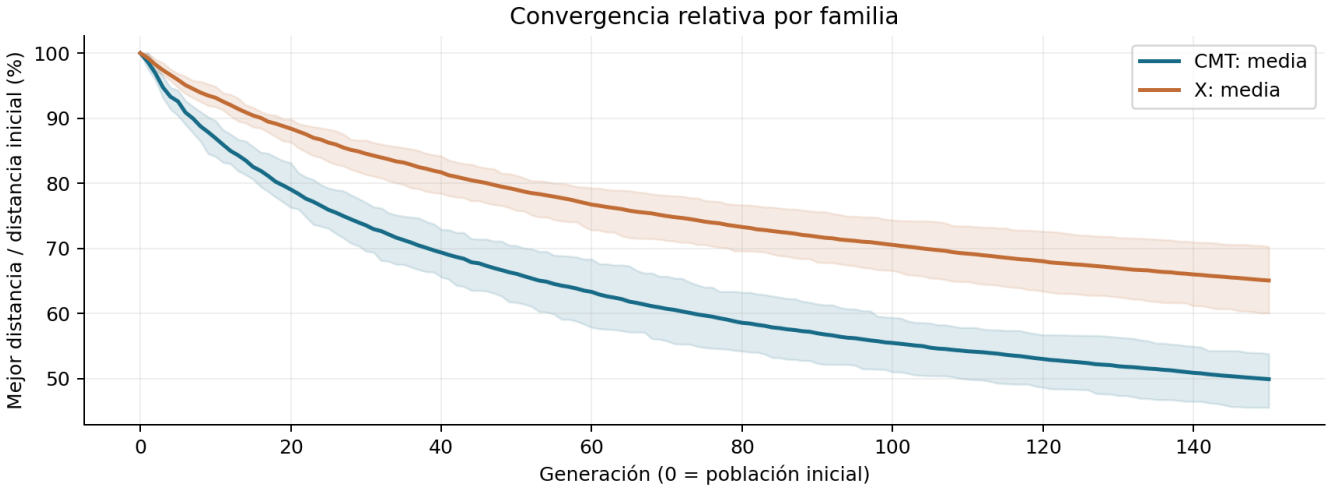


Figura 1: Mejor distancia normalizada por la mejor distancia inicial de cada corrida. Líneas: media de 42 corridas CMT y 30 X; bandas: percentiles 25 y 75, no intervalos de confianza. Menor porcentaje indica mayor reducción relativa.

El elitismo conserva los mejores individuos y explica la trayectoria no creciente del mejor costo. La normalización permite describir avance relativo sin mezclar distancias absolutas de escalas distintas; no permite comparar dificultad ni calidad final entre familias por sí sola.

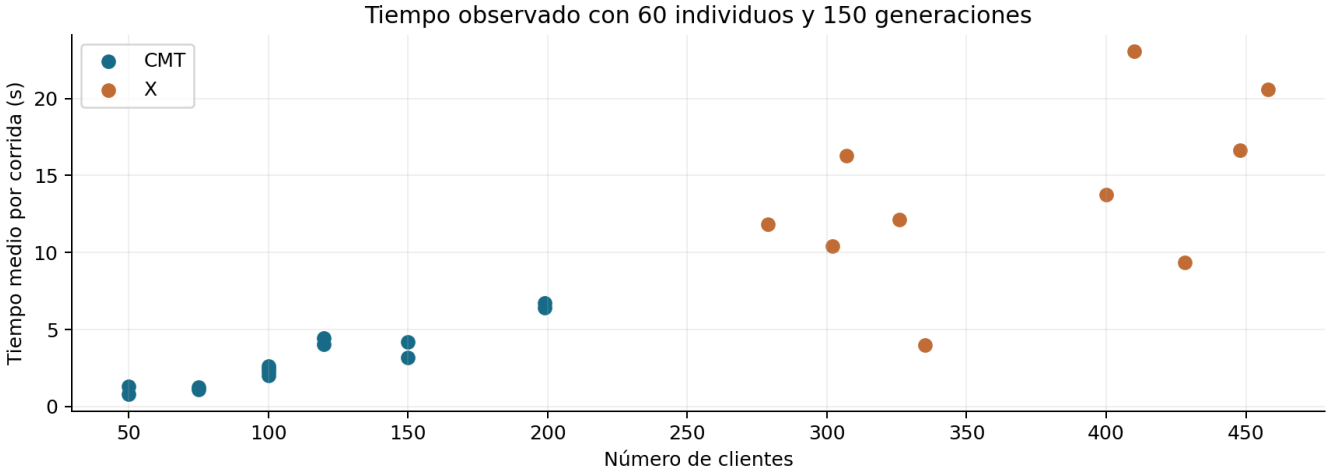


Figura 2: Tiempo medio por instancia con una configuración fija. El número de clientes no es el único factor: capacidad y duración cambian cuántos tramos factibles evalúa Split.

1.6 Ejemplo de solución y conclusiones de esta parte

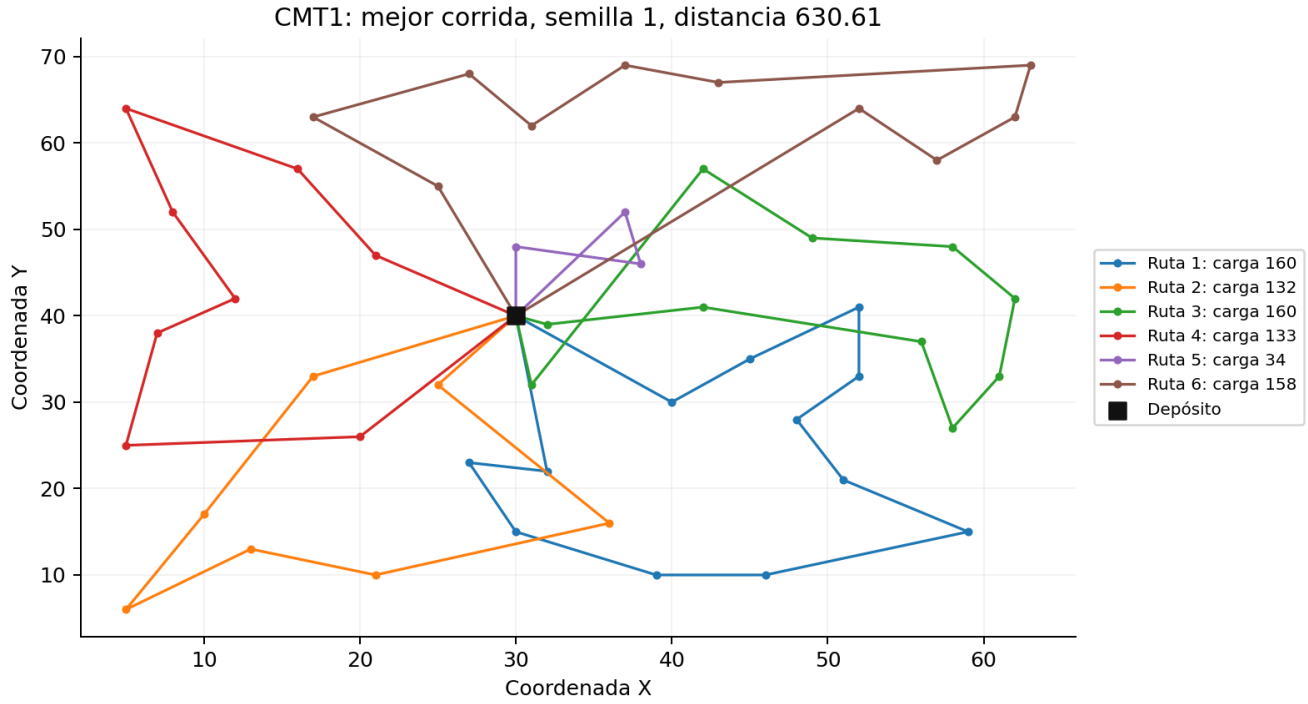


Figura 3: Mejor solución observada en CMT1. Cada color es una ruta que sale y regresa al depósito; las cargas se verificaron contra la capacidad 160.

El algoritmo de la etapa 1 pudo adaptarse a las 24 instancias y generó soluciones factibles en todas las corridas bajo las reglas declaradas. Sin embargo, el buen resultado previo en un caso de 10 clientes no se trasladó automáticamente a problemas de entre 50 y 458 clientes. La diferencia con las referencias muestra que la factibilidad y el bajo tiempo no bastan para concluir que las soluciones son competitivas.

Una explicación posible es el presupuesto fijo de población y generaciones, combinado con inicialización aleatoria y ausencia de búsqueda local. Esta es una interpretación del diseño, no una prueba causal: habría que experimentar con esas variantes para comprobarla. En esta parte se conservaron los parámetros anteriores para medir una línea base; no se hizo un estudio de sensibilidad nuevo y por tanto no se identificaron niveles “óptimos” para instancias grandes.

El estudio factorial de cruce, mutación y selección corresponde a la parte del genético asignada al otro integrante. Esta línea base puede incorporarse a esa comparación, pero no debe contarse como un algoritmo independiente si ambos usan el mismo método. La superioridad entre modelo, GA, ACO y otro método distinto sigue pendiente de integrar los resultados del equipo con reglas iguales.

1.7 Reproducibilidad e integración con el equipo

Los resultados individuales se entregan en `corridas.csv`; el resumen en `resumen.csv`; las rutas, semillas, historias y validaciones en `detalle_corridas.json`. Los metadatos incluyen versiones, plataforma, configuración y huellas SHA-256 de datos y código. Las figuras se generan desde estos resultados, sin repetir la optimización.

Desde la raíz del repositorio:

```
python -m algoritmos.propuesto.ejecutar
python -m algoritmos.propuesto.generar_reporte
python -m unittest discover -s tests -v
```

El algoritmo requiere Python 3.10 o posterior y solo biblioteca estándar. Las figuras requieren NumPy y Matplotlib. Con versiones distintas de Python, los resultados de los operadores aleatorios pueden variar aun con igual semilla. Los archivos entregados conservan las ejecuciones aquí descritas.

Antes de juntar tablas se deben confirmar la flota permitida, las distancias y la duración. Si ACO ya se ejecutó con otra convención, no basta con cambiar el nombre de la columna: es necesario recalcular o repetir la optimización según el cambio. Para el GAP con el modelo, se requiere su objetivo y estado del solver:

$$\mathrm{GAP}_{\mathrm{modelo}}(\%) = 100\frac{Z_{\mathrm{propuesto}} - Z^*_{\mathrm{modelo}}}{Z^*_{\mathrm{modelo}}},$$

solo cuando el modelo certifica optimalidad bajo las mismas reglas. Con una solución factible sin prueba de optimalidad, se reporta diferencia con el incumbente; con una cota inferior válida se informa una brecha respecto a esa cota. No se fabricaron objetivos, cotas ni estados del modelo que no se recibieron.

La validación de Split se contrastó con enumeración completa de particiones de 120 tours pequeños en cuatro regímenes de restricciones (480 comparaciones). Además se verificaron los operadores, reproducibilidad con semilla, elitismo y lectura de los 24 archivos. Esto comprueba el comportamiento del código en esos casos; no demuestra optimalidad global en las instancias experimentales.

Referencias

[1] Barrie M. Baker and M. A. Ayechew. A genetic algorithm for the vehicle routing problem. *Computers & Operations Research*, 30(5):787–800, 2003.

[2] CVRPLIB. CVRP instances. https://galgos.inf.puc-rio.br/cvrplib/index.php/en/instances/1. Consulta: 26 de octubre de 2026; valores de referencia y clasificación de optimalidad.

[3] Equipo 5. Entregable 1: Problema de ruteo de vehículos con capacidad limitada, 2026. Documento de clase proporcionado por el equipo; Anexo 3: código del algoritmo.

[4] Christian Prins. A simple and effective evolutionary algorithm for the vehicle routing problem. *Computers & Operations Research*, 31(12):1985–2002, 2004.

[5] Eduardo Uchoa, Diego Pecin, Artur Pessoa, Marcus Poggi, Thibaut Vidal, and Anand Subramanian. New benchmark instances for the capacitated vehicle routing problem. *European Journal of Operational Research*, 257(3):845–858, 2017.